Açıklanabilir Makine Öğrenmesi

Christoph Molnar — Bölüm 25 & 26 (Türkçe Çeviri)

Bölüm 25: Vekil Modeller (Surrogate Models)

Küresel bir vekil model (global surrogate model), karakutu (black box) bir modelin tahminlerine yaklaşmak üzere eğitilmiş, kendi içinde açıklanabilir bir modeldir. Vekil modeli yorumlayarak karakutu model hakkında sonuçlar çıkarabiliriz. Daha fazla makine öğrenmesi kullanarak makine öğrenmesi açıklanabilirliğini çözmek!

Matematiksel olarak şu şekilde ifade edebiliriz: Karakutu tahmin fonksiyonunu **f(x)** ve vekil modeli **g(x)** olarak adlandıralım. Eğitilen **g** modelinin kısıtı, açıklanabilir bir model türü olmasıdır (örneğin lineer model veya karar ağacı).

> Lineer Model: $g(x) = \beta_0 + \beta_1 x_1 + ... + \beta_p x_p$
>
> Karar Ağacı: $g(x) = \sum_{m=1}^{M} c_m \, I\{x \in R_m\}$

Vekil model eğitimi modelden bağımsız (model-agnostic) bir yöntemdir; çünkü karakutu modelin iç çalışma mekanizması hakkında herhangi bir bilgi gerektirmez, yalnızca verilere ve tahmin fonksiyonuna erişim yeterlidir.

VEKİL MODEL ELDE ETME ADIMLARI

Bir vekil model eğitmek için aşağıdaki adımlar izlenir:

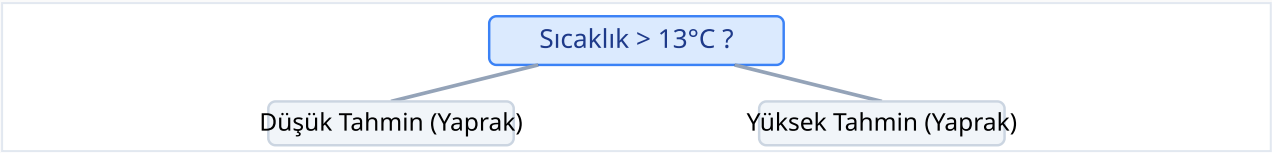
1. **Veri Kümesi Seçimi:** Bu, karakutu modeli eğitmek için kullanılan veri kümesinin aynısı veya aynı dağılımdan yeni bir veri kümesi olabilir. Uygulamanıza bağlı olarak verilerin bir alt kümesini veya bir nokta ızgarasını (grid) dahi seçebilirsiniz.
2. **Tahminleri Alma:** Seçilen veri kümesi için karakutu modelin tahminlerini ($\hat{y}$) elde edin.
3. **Açıklanabilir Model Seçimi:** Açıklanabilir bir model türü seçin (lineer model, karar ağacı vb.).
4. **Modeli Eğitme:** Açıklanabilir modeli, seçilen veri kümesi ve karakutu modelin tahminleri (hedef değişken olarak) üzerinde eğitin.
5. **Değerlendirme:** Vekil modelin karakutu modelin tahminlerini ne kadar iyi kopyaladığını (yaklaştığını) ölçün (örneğin R-kare metriği ile).
6. **Yorumlama:** Vekil modeli yorumlayın.

> 📌 **Önemli Kavram: Sadakat (Fidelity)**
>
> Vekil modelin hedefi gerçek dünya etiketlerini (y) tahmin etmek değil, karakutu modelin çıktılarını ($\hat{y}$) birebir taklit etmektir. Vekil modelin başarısı, karakutuya ne kadar sadık kaldığı ile ölçülür.

Vekil Modeller: Örnekler, Güçlü ve Zayıf Yönler

Örnek 1 (Regresyon): Bisiklet kiralama veri kümesinde günlük kiralanan bisiklet sayısını tahmin etmek için bir Destek Vektör Makinesi (SVM) eğitilmiştir. SVM doğrudan yorumlanamadığı için, SVM'nin davranışına yaklaşmak adına bir CART karar ağacı vekil model olarak eğitilmiştir. Vekil ağaç, test verilerinde 0.76 R-kare (açıklanan varyans) değerine ulaşmıştır; bu da karakutu davranışına oldukça iyi yaklaştığını gösterir.

ŞEKİL 25.1: SVM TAHMİNLERİNE YAKLAŞAN VEKİL KARAR AĞACI YAPISI



Örnek 2 (Sınıflandırma): Penguenlerin cinsiyetini (dişi/erkek) Rastgele Orman (Random Forest) ile sınıflandırdığımız ikinci bir örnekte, karar ağacı vekil modeli R-kare = 0.71 değerine ulaşmıştır.

💪 Güçlü Yönleri (Strengths)

- **Esneklik:** Herhangi bir açıklanabilir model türü ve her türlü karakutu model ile kullanılabilir.
- **Sezgisel ve Kolay:** Mantığı son derece basittir, teknik olmayan kişilere anlatması ve uygulaması kolaydır.
- **Sadakat Ölçümü:** R-kare gibi standart metriklerle vekilin karakutuyu ne kadar başardığı kolayca ölçülebilir.
- **İletişim Esnekliği:** Farklı paydaşlara (ör. lineer model sevenler vs. ağaç sevenler) aynı karakutu için farklı vekiller sunulabilir.

⚠️ Zayıf Yönleri (Limitations)

- **İllüzyon Riski:** Vekil model karakutunun ne yaptığını açıklar, *gerçek dünyanın nasıl çalıştığını değil*.
- **Mükemmel Olmayan Uyum:** R-kare %100 değilse, vekil model karakutunun bazı karmaşık kararlarını kaçırıyor demektir.
- **Kesim Noktası İkilemi:** Vekil model karakutuyu çok iyi açıklıyorsa ($R^2 \approx 1$), karakutuyu çöpe atıp doğrudan vekil modeli kullanmamak için bir sebep kalmaz.